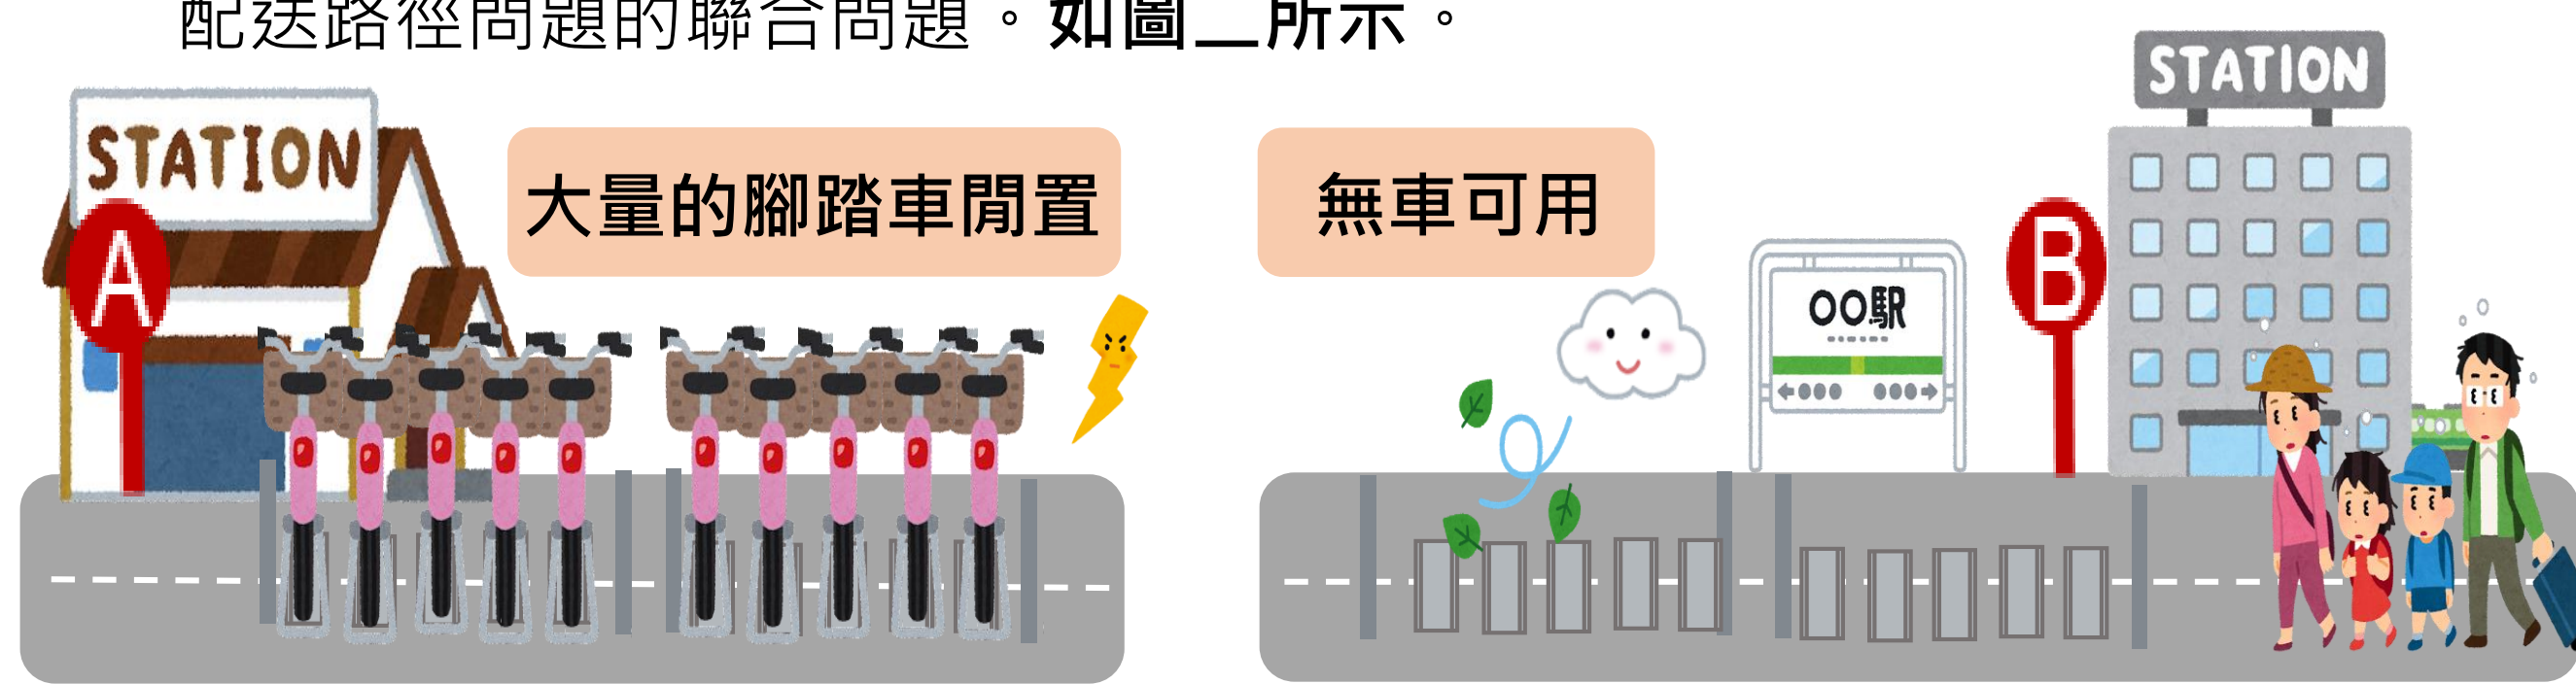


# 結合深度學習預測站點供需量之共享單車再配送路徑問題 Sharing Bicycle Redistribution Routing Problem Integrating Station Demand Forecasting Using Deep Learning

指導教授：林春成<sup>1</sup> & 專題成員：江詠筑<sup>1</sup>、謝惠喻<sup>2</sup>、鄭志權<sup>1</sup>、顏語<sup>1</sup>  
國立陽明交通大學工業工程與管理系<sup>1</sup>、國立陽明交通大學資訊工程學系<sup>2</sup>

## 1. 研究目的

- 共享經濟在全球興起的浪潮促使了大量資金與技術投入共享單車系統 (Bicycle Sharing System)。因為共享單車環保且能防止交通擁堵，因此共享單車是取代傳統公共交通工具的有效選擇。此外，共享單車能減少公共場所的社交接觸風險，因此在COVID-19疫情嚴峻的今日尤其重要。
- 如圖一所示，共享單車在需求不確定下容易出現供需失衡，且平台之經營上也缺少良好的單車再配送調度策略，所以成功的共享單車系統寥若晨星。因此近年來吸引許多學者投入研究改進共享單車系統。先前研究大多分別考慮共享單車站點需求預測 (Station Demand Forecasting) 或共享單車再配送路徑規劃 (Sharing Bicycle Redistribution Routing)。
- 然而只考慮前者是無法實際調整站點共享單車數量，而只考慮後者亦僅是依照歷史資料進行路徑最佳化，卻無法有效因應對現實中時空變動的單車需求。因此，本研究提出同時考慮共享單車站點需求預測和共享單車再配送路徑問題的聯合問題。如圖二所示。



圖一、共享單車系統常見之站點單車數量供需失衡問題示意圖

## 2. 系統架構



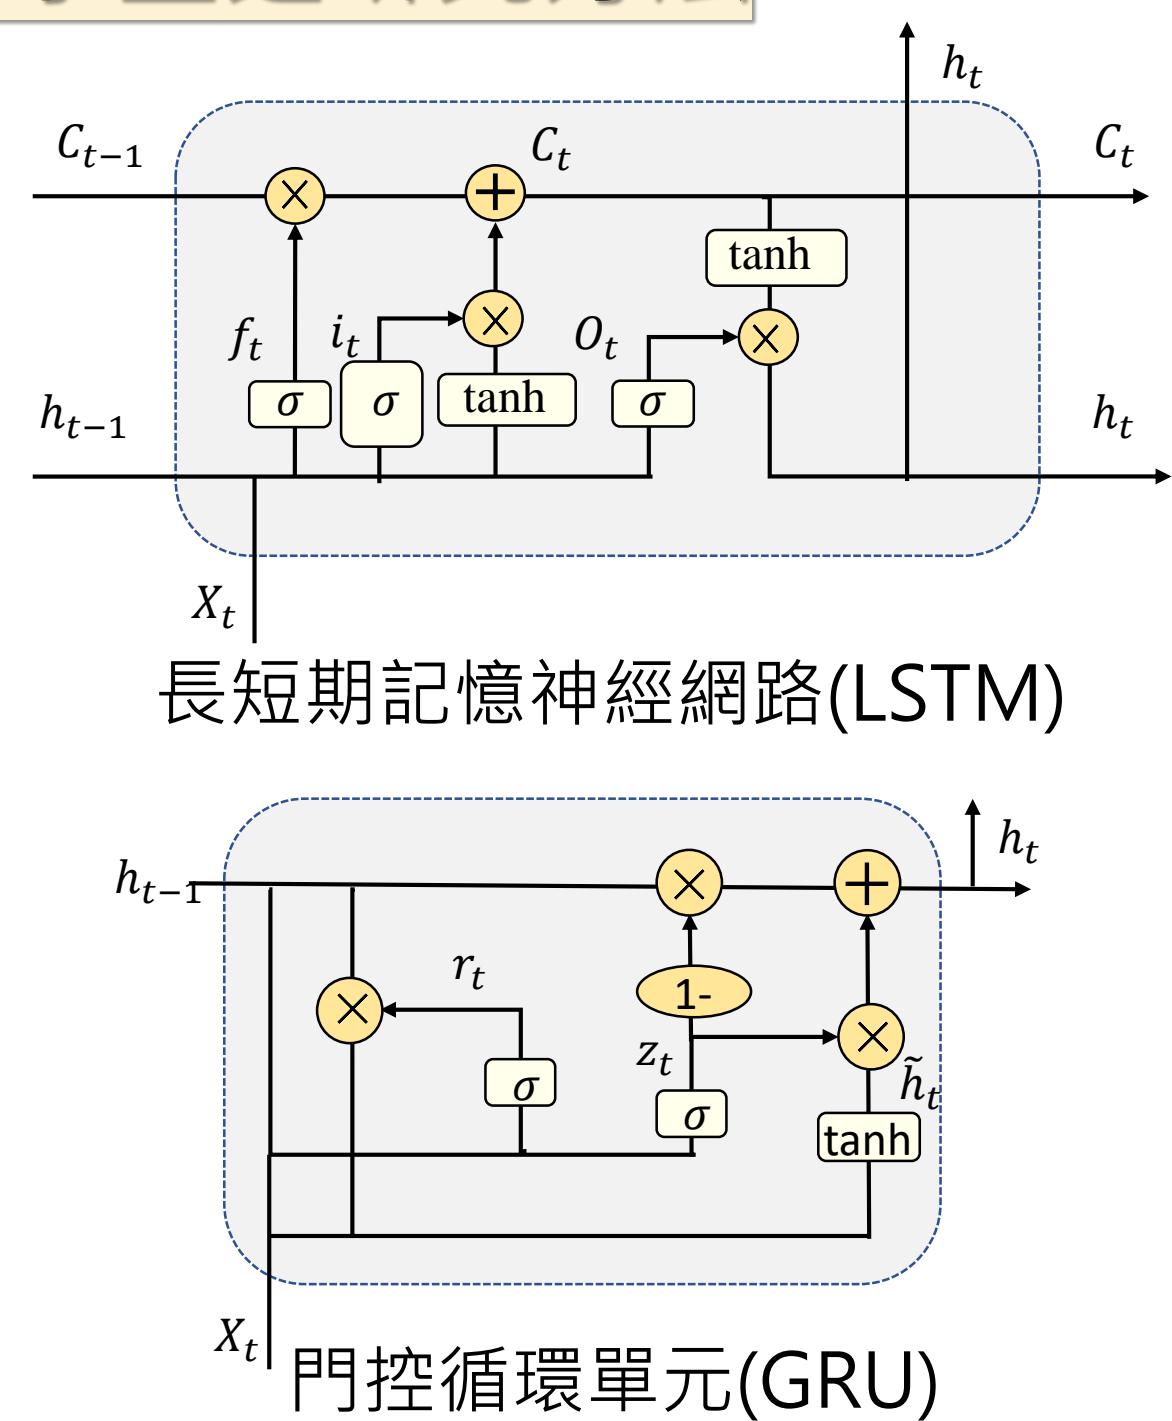
圖二、共享單車需求預測下之貨車再配送系統架構

- 我們結合需求預測與再配送路徑規劃，提出整合性系統。此系統架構如圖二所示。
- 共享單車站點需求預測為時間序列預測問題 (Time Series Forecasting)，而共享單車再配送路徑規劃是一種收送貨車輛途程 (Vehicle Routing Problem with Pickup and Delivery, VRPPD)，屬於 NP-hard 複雜問題。

## 3. 研究方法

### 第一階段以深度學習法預測共享單車需求量之研究方法

- 循環神經網路(RNN)的目標是希望能透過觀察序列中的先前步驟進而預測該序列下一步的情況，不過因為該種神經網路只能記住序列中較早的幾個步驟，一旦距離當前的時間步越長，那麼其反饋的梯度訊號則會越不顯著。
- 長短期記憶神經網路(LSTM)是RNN的一種特殊架構可以處理有序數據並長期記憶過去時間步長的數據，因此可以解決RNN梯度消失的問題，不受梯度消失或梯度爆炸的影響。
- 門控循環單元(GRU)也是用來解決梯度問題的RNN變形，但是相較於LSTM，GRU技術大幅加快執行速度以及減少記憶體體的耗用，其原因來自於參數的減少。
- 為了避免梯度消失或爆炸的問題，因此本研究主要使用LSTM、GRU技術為預測模型的基礎結構。



圖三、本研究深度學習預測模型之模型結構

### 第二階段以基因演算法找出最佳再配送路徑之研究方法

- 首先建立最佳再配送路徑問題之數學模型，接著提出基因演算法求解此問題。
- 將成本函數設定為目標式(1)，以最小化貨車總距離及最小化碳排放量之雙目標求解，本研究之基因演算法所得之最佳解為行駛總距離最少時排放最少碳的解。
- 基因演算法是應用自然界的演化及淘汰的概念，採多點搜尋，可跳脫局部最佳解，能得近似全域最佳解，因此我們將採用基因演算法作為本研究問題最佳化演算法。
- 給定一組染色體  $(k_1, k_2, \dots, k_n)$ 、 $(b_1, b_2, \dots, b_{2C})$ ，適應度值根據前述混合整數線性規劃模型之限制式計算，以取得最小之適應度值，且當違背限制式，如貨車即時載重超過最大載重，或是小於0時，將適應度值，也就是行使距離設為100000。

目標式(1) Minimize  $Z = \alpha z_1 + \beta z_2$

運輸成本  $= \alpha \times (\sum_{i=0}^n \sum_{j=0}^n X_{ij} d_{ij})$


碳排放成本  $= \beta \times (\sum_{i=1}^n \sum_{j=1}^n y_{ij} \times [(F^* - F)/Q] \times d_{ij} \times X_{ij})$

$x_{ij} = 1$  若貨車從站點 i 行駛到站點 j  
 $y_{ij}$  站點 i 到站點 j 貨車上的共享單車數量  
 $d_{ij}$  站點 i 到站點 j 的距離


貨車可以承載的最大單車數量

貨車滿載時的CO2排放因子 貨車空載時的CO2排放因子

## 4. 實驗結果與討論



圖四、共享單車租賃數與不同特徵的資料分析(由左至右為月份/年份)

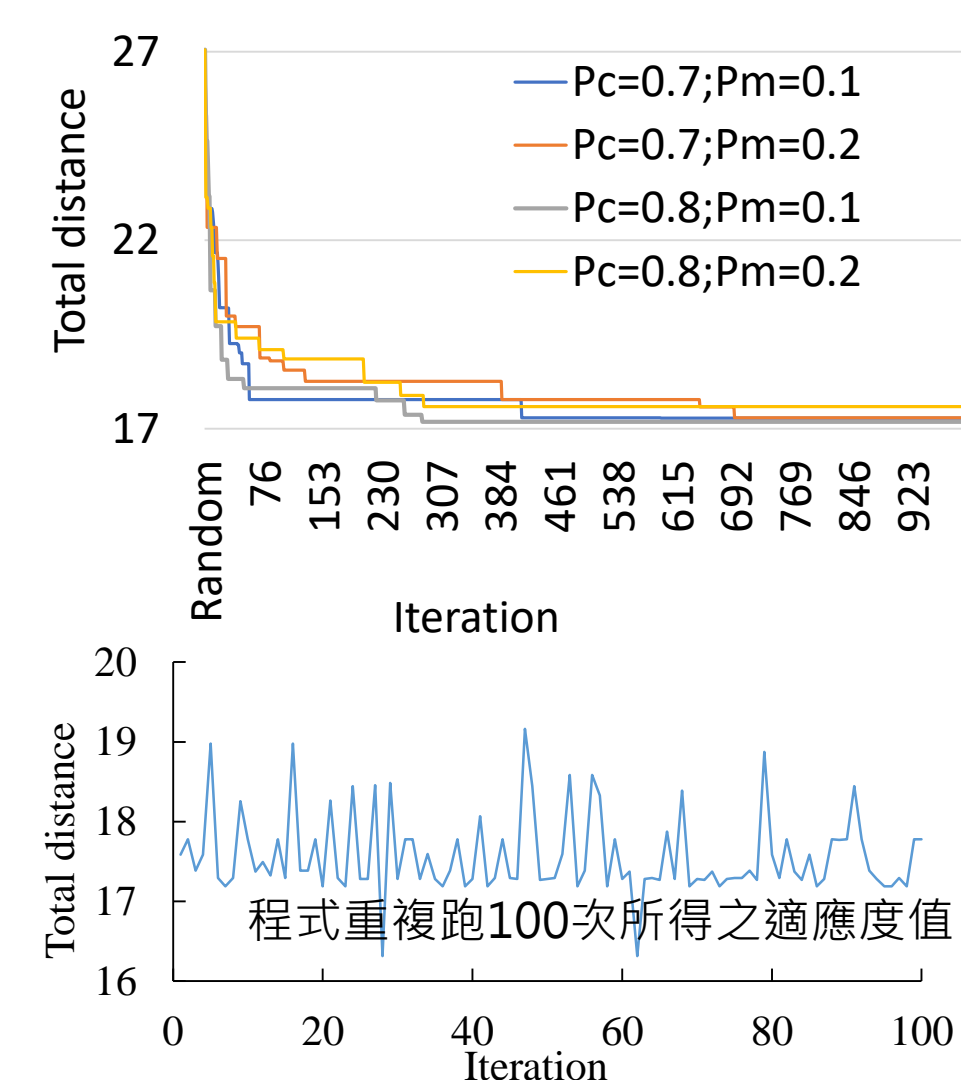


圖五、深度學習各模型之預測效能MSE

- 根據圖四的實驗資料分析，我們決定把時間和月份作為特徵輸入，除了時間和月份外，亦有額外加入星期來作為特徵之一，嘗試提高預測準確性。
- 本研究利用Keras中的LSTM、GRU來建立預測模型並針對這三種架構的預測結果進行誤差評估、比較：
- 1) 架構1：堆疊二層LSTM後加上一層Dropout層來防止過擬和，最後再堆疊兩層的全連接層來輸出。
- 2) 架構2：堆疊四層LSTM後加上一層Dropout層來防止過擬和，最後再堆疊兩層的全連接層來輸出。
- 3) 架構3：堆疊二層GRU後加上一層Dropout層來防止過擬和，最後再堆疊兩層的全連接層來輸出。
- 圖五便是架構1、2、3進出站模型的MSE值。不論任何架構下的MSE皆會遵循一定的規律產生，例如，不論哪個架構下的MSE均為Station 2最為嚴重，除此之外，我們可以發現出站模型的MSE通常會比進站模型的MSE來的更小。

Q	Q <sub>0</sub>	C	P <sub>c</sub>	P <sub>m</sub>	Best distance
10	5	3	0.8	0.1	20.173188
10	5	4	0.8	0.1	20.792860
10	5	5	0.8	0.1	23.210680
20	5	3	0.8	0.1	21.254345
20	5	4	0.8	0.1	20.270460
20	5	5	0.8	0.1	21.232755
20	10	3	0.8	0.1	17.383286
20	10	4	0.8	0.1	17.294051
20	10	5	0.8	0.1	18.457814
20	15	3	0.8	0.1	17.699186
20	15	4	0.8	0.1	19.660896
20	15	5	0.8	0.1	17.167029
30	10	3	0.8	0.1	17.777345
30	10	4	0.8	0.1	18.580679
30	10	5	0.8	0.1	18.74622
30	15	3	0.8	0.1	17.189376
30	15	4	0.8	0.1	18.255538
30	15	5	0.8	0.1	18.255538
30	20	3	0.8	0.1	17.777345
30	20	4	0.8	0.1	17.189376
30	20	5	0.8	0.1	18.457814

表1、問題參數設定及結果比較



圖六、收斂度與穩定度分析

- 由圖六分析，當  $P_c = 0.8$  和  $P_m = 0.1$  時，可得最佳解有最佳收斂效率，因此本研究接下來將使用此參數設定。
- 從表1實驗結果，若共享單車系統欲最小化再配送階段的總距離與碳排放，對於再配送貨車的添購，我們建議：
- 1) 若預算充足，儘量買最大容量夠多的，在此實驗中約為平均裝載、卸載數量的六倍。
- 2) 若預算不足，最大容量不高時，初始載重量，也就是出倉庫時貨車上的共享單車數量應該要約為最大載重量的50 ~ 75%為佳。
- 3) 無論最大載重或初始載重的設計，建議約5 ~ 7個站點分配一台貨車。例如在本研究實驗中，我們20個站點的最佳貨車數量就大多落在3或4台。
- 最後，這三個建議都能夠大幅度的減少總距離及碳排放，達到共享單車系統節能減碳、永續經營的目標。

SDG 9 SDG11 SDGs 重要度與貢獻 SDG13 SDG17

- 共享單車系統提供可使用/永續的公共交通工具
- 共享單車建立符合永續發展目標的營運績效指標
- 結合需求預測之最佳化再配送路徑可減少碳排放
- 此專題研究方法可促進永續的工商業及提高GDP