

結合深度學習預測站點供需量之共享單車再配送路徑問題

Sharing Bicycle Redistribution Routing Problem Integrating Station Demand Forecasting Using Deep Learning

謝惠喻、江詠筑*、鄭志權、顏語

*通訊作者：yungchu.mg08@nycu.edu.tw

摘要

共享經濟在全球興起的浪潮促使了大量資金與技術投入共享單車系統 (Bicycle Sharing System)。因為共享單車環保且能防止交通擁堵，因此共享單車是取代傳統公共交通工具的有效選擇。此外，共享單車能減少主要發生在公共場所的社交接觸的任何可能風險，因此在 COVID-19 疫情嚴峻的今日尤其重要。然而，共享單車在需求不確定下容易出現供需失衡，且平台之經營上也缺少良好的單車再配送調度策略，所以成功的共享單車系統寥若晨星，因此近年來吸引許多學者投入研究改進共享單車系統。先前研究大多分別考慮共享單車站點需求預測 (Station Demand Forecasting) 或共享單車再配送路徑規劃 (Sharing Bicycle Redistribution Routing)，然而只考慮前者是無法實際調整站點共享單車數量，而只考慮後者亦僅是依照歷史資料進行路徑最佳化，卻無法有效因應對現實中時空變動的單車需求量。

因此，本研究提出同時考慮共享單車站點需求預測和共享單車再配送路徑問題的聯合問題 (Integrating Sharing Bicycle Redistribution Routing Problem with Station Demand Forecasting)，其中共享單車站點需求預測為時間序列預測問題 (Time Series Forecasting)，而共享單車再配送路徑規劃是一種收送貨車輛途程 (Vehicle Routing Problem with Pickup and Delivery, VRPPD)，屬於 NP-hard 複雜問題。本研究進一步提出深度學習 (Deep Learning) 的長短期記憶模型 (Long Short-Term Memory, LSTM) 和門控循環單元模型 (Gated Recurrent Unit, GRU) 來建立三種預測模型來預測未來每個時間點每個站點的共享單車需求量，接著再以預測出的各站點單車進出量為再配送模型的輸入，以最小化碳排放和再配送貨車總路徑長為最終雙目標建立數學規劃模型 (Mathematical Programming)，最後用基因演算法 (Genetic Algorithm) 規劃最佳的共享單車再配送路徑。為評估所提出之方法，本研究以位於華盛頓特區的美國最大共享單車系統 Capital Bikeshare 之大量歷史資料及影響需求的屬性為模擬實驗資料集做測試，實驗證實以 Keras 開源程式庫實作的本研究提出之方法能減少 36% 的總距離及碳排放，達到共享單車系統節能減碳、永續經營的目標。

關鍵字：共享單車系統、共享單車再配送路徑問題、深度學習、數學規劃、基因演算法、單車需求預測

1. 背景與目的

近年來共享單車順應著共享經濟的概念興起逐漸蔚為風行，全球共享單車市場預計到 2025 年將超過 50 億美元，許多地區均已設有商業性的共享單車系統 (Bicycle Sharing System, BSS)。共享單車系統 BSS 藉由提供租借單車的服務創造利益，使用者則藉此以平價的租借費滿足騎乘單車需求，共享單車相較其他的交通工具也能有效降低碳排放的汙染，進而創造更美好的環境品質。然而，共享單車各站點供需失衡的問題導致無車可借或大量單車閒置的情況處處可見，使用者滿意度下降、平台也因此獲利不佳，新創小公司更是容易破產，共享單車的名聲大不如前。許多研究證實，若要建立一個良好且有商業價值的共享單車系統，一個永續且完善的系統配置是必須研究並實行的重要目標。

為了解決站點供需失衡問題，共享單車系統多半會以貨車進行共享單車再配送調度 (Bicycle Redistribution)，但隨意配送難以達到最佳解，因此有許多研究投入以數學規劃模型、萬用啟發式演算法解決相關的共享單車再配送調度問題。除了以車輛再配送調度解決供需失衡的問題外，也有一部份研究直接從共享單車站點需求預測 (Station

Demand Forecasting) 著手，解決根本的需求不確定性引發之失衡問題。由於過去研究僅專注在單一共享單車站點需求預測或共享單車再配送路徑規劃，然而前者無法實際調整站點共享單車數量；後者僅依照歷史資料進行路徑最佳化，但未來環境與過去環境的差異會導致舊有的最佳化路徑無法套用。此外，近年來由於環境保護意識高漲，減少對環境的破壞成為全球關注的重要議題。雖然共享單車已是綠色交通的一大代表，然而若忽略需求失衡的問題，共享單車再配送階段的碳排放及能源消耗將使得共享單車系統背離原先永續經營的初衷。

因此，本研究提出同時考慮共享單車站點需求預測和共享單車再配送路徑問題的聯合問題 (Integrating Sharing Bicycle Redistribution Routing Problem with Station Demand Forecasting)，如圖 1 所示，其中共享單車站點需求預測為時間序列預測問題 (Time Series Forecasting)，而共享單車再配送路徑規劃是一種收送貨車輛途程 (Vehicle Routing Problem with Pickup and Delivery, VRPPD)，屬於 NP-hard 複雜問題。本研究進一步提出深度學習 (Deep Learning) 的長短期記憶模型 (Long Short-Term Memory, LSTM) 和門控循環單元模型 (Gated Recurrent Unit, GRU) 來建立三種預測模型來預測未來每個時間點每個站點的共享單車需

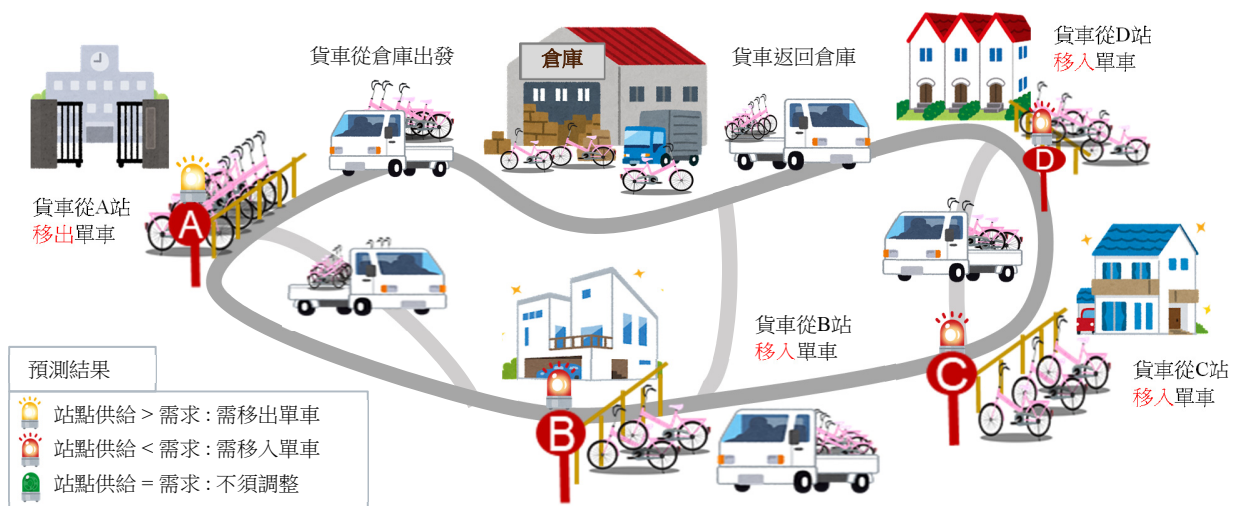


圖 1、需求預測下之共享單車再配送問題示意圖

求量，接著再以預測出的各站點單車進出量為再配送模型的輸入，以最小化碳排放和再配送貨車總路徑長為最終雙目標建立數學規劃模型 (Mathematical Programming)，最後用基因演算法 (Genetic Algorithm) 規劃最佳的共享單車再配送路徑。本研究主要貢獻如下：

- 盡我們所知的，過去未有研究考慮結合深度學習預測各站點需求和共享單車再配送路徑規劃問題，因此本研究為第一個研究結合共享單車站點需求預測下之共享單車再配送路徑問題。
- 本研究提出以深度學習的LSTM和GRU來建立三種預測模型來預測未來每個時間點每個站點的共享單車需求，最後用基因演算法規劃最佳的共享單車再配送路徑。
- 本研究的實驗結果分析可得知，本研究所提出的預測需求下之最小化再配送階段的總距離與碳排放，只要共享單車系統依循我們最佳系統配置建議，即可有效為共享單車系統節省約36%的總成本。

本研究剩餘部分結構如下：第二章為文獻回顧，第三章為本研究問題設定，第四章介紹本研究第一階段以深度學習法預測共享單車需求，而第五章則是介紹本研究第二階段以基因演算法找出最佳再配送路徑，第六章為實驗設定與實驗結果，第七章則為本研究之結論。

2. 文獻探討

本章首先回顧共享單車預測問題，接著回顧最佳共享單車再配送路徑問題，最終總結我們的研究問題。

2.1 共享單車預測問題

2.1.1 時空因素對預測模型之影響

近年來計算智慧運輸系統的預測模型得到了廣泛且充足的研究(Chen and Jakubowicz, 2015; Chen and Zhang, 2014)。當中關於預測共享單車系統，如何分析類別型數據與預測結果之間的相關性是精準預測的一個挑戰。一些研

究對共享單車系統的影響因素進行了大量研究。例如，Gebhart and Noland (2014) 分析了天氣因素對共享單車使用的影響。Bachand-marleau et al. (2012) 調查了社會經濟和空間因素，並進一步分析了它們對使用頻率的影響。雖然這些研究未能捕捉到複雜的時空特徵，但它們確實闡明了外部因素在預測模型中的重要性。另一方面，由於交通系統本身的複雜性，接收到的數據會隨著時間和空間的不斷變化而變化。如何探索時空數據的波動性和對複雜的非線性關係進行建模是另一個具有挑戰性的問題。幸運的是，深度學習建模的最新的進展解決了許多關於開發交通預測方法的挑戰 (LeChun et al., 2015)。

2.1.2 統計分析、非線性理論

預測共享單車需求是再平衡策略中的重要部分，早期在機器學習尚未普及的時代，大多數研究主要使用數學理論，如統計分析、非線性理論等方式來建立模型。例如，Gast et al. (2015) 基於一種非均勻排隊模型所獲得的預測概率來推估共享單車站點的單車數量是否足夠使用。Ashqar et al. (2017) 使用單變量回歸和多變量回歸方法分別對每個站點和每個區域的空間相關站點的可用自行車進行建模。

2.1.3 機器學習

有許多潛在因素會影響回歸分析模型的準確度，隨著人工神經網路(Artificial Neural Network, ANN)的盛起，機器學習、深度學習等技術也在共享單車的研究得到廣泛的應用。例如，Cho et al. (2020)在考慮季節變化的條件下利用隨機森林演算法(Random Forest, RF)來預測共享單車使用量。此外，倒傳遞神經網路具有良好的適應性，其數據可以透過學習來解決非線性問題。例如，Lee et al. (2018)是利用 Fuzzy C-means-based GA 的方式針對歷史數據進行分類，然後將分類結果輸入進 Back-Propagation Network (BPN)預測器中進行訓練，訓練過後的 BPN 預測器便可預測未來的單車需求數量。此外，有研究針對不同機器學習的模型進行預測誤差比較。例如，Zuo et al. (2017)利用單

車用戶歷史資訊、天氣資訊以及假期資訊三種不同的資料來源轉換為合適的模型訓練格式，此外，此研究使用多元線性回歸模型、決策樹、隨機森林三種不同的預測方式進行模型訓練，最後結果得知隨機森林的預測效果最佳，後續便重點關注隨機森林模型的分析，並對其進行優化，以進一步提高預測效果。

2.1.4 遞迴神經網路

深度學習中循環神經網路(Recurrent Neural Network, RNN)擅長處理連續時間序列數據，但該模型操作時容易產生梯度消失和梯度爆炸的問題，因此長短期記憶網路 LSTM 的出現便改進 RNN 所發生的問題，該模型在時間序列的研究中得到廣泛的應用並取得很好的效果。例如，Pan et al. (2019)基於時間、天氣、歷史數據來訓練一個兩層的 LSTM 模型來預測單車的租賃和歸還，並透過比較不同模型的均方根誤差(Root Mean Square Error, RMSE)來凸顯 LSTM 的預測能力。Wang et al. (2018)利用 LSTM、GRU、RF 等模型來預測站點中可用的單車數量，並選擇均方誤差 (Mean Square Error, MSE)、平均絕對誤差 (Mean Absolute Error, MAE)、平均絕對百分比誤差 (Mean Absolute Percentage Error, MAPE) 做為評估三個模型的效能標準。根據預測結果，我們發現這三種模型在可用單車數量的短期預測中都表現良好，此外，LSTM 和 GRU 的結果在預測行為上非常相似，但 GRU 比 LSTM 具有更準確結果和更快訓練時間，且由於訓練時間短，沒有複雜的超參數設置，隨機森林需要較少的計算資源，更容易訓練。

Han et al. (2020)使用共享單車系統所收集的單車需求數據集在實際操作中評估了機器學習、神經網路模型的效能，並利用 XGBoost 和隨機森林模型當成機器學習模型、LSTM 和 GRU 模型來當作神經網路模型。在所有模型當中，XGBoost 模型對平均 MSE 和 MAE 的誤差預測最高。GRU 模型產生了關於平均 MSE 和 MAE 的最低誤差預測。

2.2 共享單車再配送問題

許多文獻探討共享單車系統需求分佈失衡的問題。例如空位過多導致大量無效需求，或供不應求以至於無法滿足用戶需求。目前市面上的共享單車供應商主要使用共享單車再配送來解決失衡問題，只要當時站點共享單車數量沒有在他們設定的庫存水準就立刻從倉庫發貨車前往調整。然而此方法既費時又費力，亦有顯著時空延遲。許多研究(Hou and Edara, 2018; Ma et al., 2019; Chen et al., 2017)證實解決此問題最好的方法是建立一個永續的整合性系統，包含建立精準預測模型及單車再配送路徑規劃。單車再配送方面，共享單車再平衡問題(Bicycle Rebalancing problem, BRP)源於收送貨車輛途程問題 (Vehicle Routing Problem with Pickup and Delivering, VRPPD)，且涵蓋靜態及動態共享單車貨車再平衡兩大流派。

2.2.1 車輛路徑問題(VRP)

關於倉庫和最終用戶之間貨物分配的問題被稱為車輛路線問題 (Vehicle Routing Problem, VRP)。VRP 的典型應用是固體廢物收集、街道清潔、校車路線、殘疾人運輸等。在本論文中，我們考慮了載貨車輛路徑問題，它是有

容量限制的車輛路徑問題(Capacitated VRP, CVRP)之延伸應用，且都來源於並包含了經典的旅行推銷員問題 (Travelling Salesman Problem, TSP)。其固有的複雜性使他們成為 NP-hard 問題，意即若非 $P = NP$ ，否則不可能在多項式時間內解決 NP-hard 問題。Dantzig & Ramser (1959)介紹了 VRP。作者描述了一個現實世界的應用，並提出了第一個數學規劃公式和六種啟發式演算法來解決這個問題，實驗結果也證實基因演算法是解決 VRP 效果最顯著的方法。其中的數學模型套用至共享單車貨車再平衡問題的基本描述大致如下：令 $G = (V, A)$ 是一個圖，其中 $V = \{v_0, v_1, \dots, v_n\}$ 是一個節點集， $A = \{(v_i, v_j) : v_i, v_j \in V, i \neq j\}$ 是一個弧集。 v_0 代表存放大量共享單車的倉庫， v_i 代表各個共享單車的站點。每個客戶都只能有一個非負的交付需求(q_i)。VRP 包括以最小成本找到一組車輛路線，使得：

- 1) 每條路線都在倉庫開始和結束。
- 2) 每個一輛車只拜訪每個需求站點一次。
- 3) 每條路線的總需求不超過車輛容量限制。
- 4) 每條路線的總持續時間不超過當前限制。
- 5) 總路線成本最小化。

2.2.2 收送貨車輛途程問題(VRPPD)

VRPPD 在基本 VRP 的基礎上進行了一些擴展 (Toth and Vigo, 2002)，成為一個包含提貨(Pickup)和交貨(Delivery)的車輛路徑問題(VRPPD)。其中的提貨需求即為負需求，因此可以將 VRP 中需求的非負限制擴展到可以為任意整數，讓每個站點可以有兩種需求：提貨需求(Pickup)和交付需求(Delivery)。這個改變理論上如同透過將正負數拆成兩個正數去除 VRP 的非負限制式。在本研究中，交貨需求(p_i)是指貨車需從倉庫運送並移入到各站點的共享單車數量，而提貨需求(d_i)是指貨車需從各站點移出並運送回到倉庫的共享單車數量。在此研究中，VRPPD 之交付或提貨需求定義為深度學習共享單車預測的淨數量，進站量減出站量，若大於零，將其絕對值設為交付需求；若小於零，則將其絕對值設為提貨需求。

2.2.3 靜態共享單車貨車再平衡問題

首先，靜態單車再平衡問題(Static BRP, SBRP)假設再配送發生在晚上，並且在此期間用戶的需求小到可以忽略不計。Benchimol et al. (2011) 定義靜態共享單車貨車再平衡問題，並指出其問題與一些經典問題例如一個商品取貨配送問題、交換問題和 C-delivery TSP 的相同及相異處，他們所提出的方法問題亦可看作是一個具有容量限制的商品交換問題，其目標是透過使用一系列移動的最小成本將所有站點從初始狀態調整到目標狀態。在靜態版本中，採用站點佔用級別的短時需求，然後用於規劃重新分配。

2.2.4 動態共享單車貨車再平衡問題

其次，動態共享單車貨車再平衡問題(Dynamic BRP, DBRP)假設再配送操作在白天進行的，用戶的需求是即時變化的。在動態再平衡問題中，共享單車系統的實時 (Real-

time) 使用是很重要的考量依據，也就是說，如果做決策所需的時間大於再配送過程所需要的時間，共享單車再平衡路徑就沒有實際價值，需要重新計算。Hu et al. (2021) 將問題表述為混合整數線性規劃 (Mixed-Integer Linear Programming, MILP) 並且以分裂層次聚類算法提出了一種基於細節層次模型結合基因演算法的再平衡策略。雙目標中考慮了運營成本及用戶滿意度函數，透過對比實驗驗證可提高共享單車系統的運行效率，降低管理成本。

2.3 小結

過去研究大多僅侷限於單一需求預測或單一再配送路徑規劃之調度問題。因此，本研究聯合需求預測與再配送路徑規劃，嘗試建立一個永續的整合性系統。該問題涉及使用歷史數據集預測未來某個站點的自行車租賃和歸還數量，以及收送貨車輛途程問題 (VRPPD) 解法，可為交通需求預測提供有價值的見解。

Qin et al. (2021) 實驗證實最小化碳排放的目標式與貨車行駛路線優化正相關，並說明若能對每個站點明確的供需模型會對最小化再配送碳排放有非常大的幫助。與本研究不同的是，上述研究採取靜態再配送，僅於夜間或使用次數很少時才能以當前資料進行再配送。而本研究則是介於靜態與動態間的以小時為單位再配送。因此，本研究實際引入 (Qin et al., 2021) 最小碳排放模型，結合 (Hu et al., 2021) 的最小總距離目標，與前面研究最大的不同是以往單純再配送路徑或全站點總和的需求預測問題研究，本研究保留她們部分的數學模型，並且多增加以站點為單位的深度學習預測。能提早一個小時對站點進出量做最佳路徑規劃，可讓再配送階段的貨車產生更少的 CO₂ 排放量。

3. 問題設定

本章介紹本研究討論問題設定。本研究問題之假設如下，當中前四點參考之先前研究，後四點為本研究新增之設定：

- 1) 本研究由多輛貨車共同進行單車配送物流作業。
- 2) 貨車由調度中心(存放單車之倉庫)出發，最後回到調度中心。
- 3) 運送單車之貨車有容量上限。
- 4) 資料來自於華盛頓特區的單車租借狀況，因此在預測需求方面會與該區的實際情況較為符合。
- 5) 各個站點在每隔一段時間(一小時)做一次預測及規劃，且此時間內可重複進行。
- 6) 假設調整共享單車數量(移入或移出)所需時間極短。
- 7) 本研究探討一般使用者的租賃行為，未將路線的臨時狀況與保養維護列入考慮，因此假設貨車到各站點所需時間與距離成正比。
- 8) 所有規畫完成的路徑可在一小時內配送完成。

接著，我們先介紹第一階段的預測站點供需量之問題設定，接著根據所獲得供需量資訊來進行第二階段的最佳共享單車再配送路徑。

3.1 預測各個站點再配送調整之單車數量

本研究第一階段的問題是考慮美國 Capital Bikeshare 平台中華盛頓特區前 20 多單車租賃筆數的站點進行分析及預測。不同於過去研究(如 Wang et al., 2015)僅針對站點中單車可用數量進行預測，本研究則是針對站點中單車進站(Arrival)及出站(Departure)狀況分別建構兩個模型進行預測，流程圖如圖 2 所示。若能精準的預測兩個數量的話，則我們將兩個模型的預測結果相減後便可得出該站點所預測的淨單車數量變化，將此預測結果設定為站點所需調整之單車數量，利用此預測結果導入至路徑規劃模型來預測最佳路徑。此外，由於各站點的實際單車租借狀況會有一定差異，因此本研究針對每一個站點 (Every Station) 個別建立單車進站、進站數量預測模型，在算出所有站點所需調整單車數量後，便可將預測結果導入路徑規劃模型。

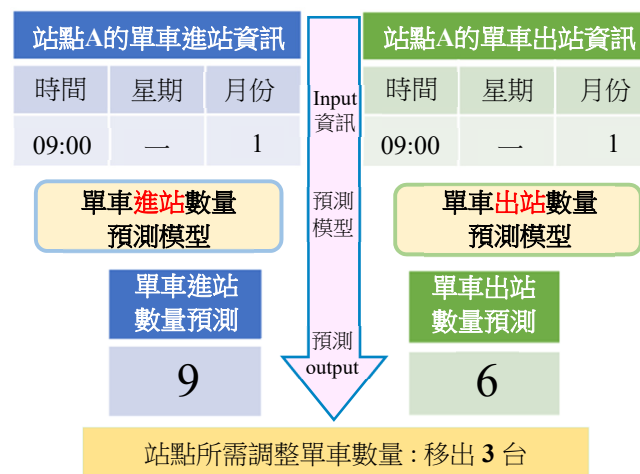


圖 2、第一階段問題預測各站點所需單車量之流程圖

3.2 最佳化單車再配送路徑

本研究第二階段的問題是如何根據第一階段所算出的所有站點所需調整的單車數量來進行路徑規劃。本研究考慮有多台貨車和多個共享單車站點，當中共享單車站點依照預測狀況分成三種：

- 1) 該站點預測之每小時進站量大於出站量、
- 2) 該站點預測之每小時進站量小於出站量、
- 3) 該站點預測之每小時進站量等於出站量。

本研究第二階段的問題實例如圖 3(a)所示，當中：

- 灰色矩形為共享單車倉庫為貨車的出發與結束位置，我們假設為各個站點範圍的中心點；
- 黃色圓形代表預測下個時段該站點進入單車較多，因此下個時段可能缺乏停車樁可停車，需要貨車移出單車以避免無樁可停的情形；
- 藍色圓形代表預測下個時段該站點離開單車較多，下個時段可能缺單車，需要貨車移入單車以避免無車可用的情形；

- 綠色圓形代表預測下個時段該站點進出平衡，無須調整，則貨車不會造訪該站點。

本研究第二階段的問題，是根據圖3(b)所獲得的資訊，找出一個可行的多台貨車運送單車至各站點的路徑。

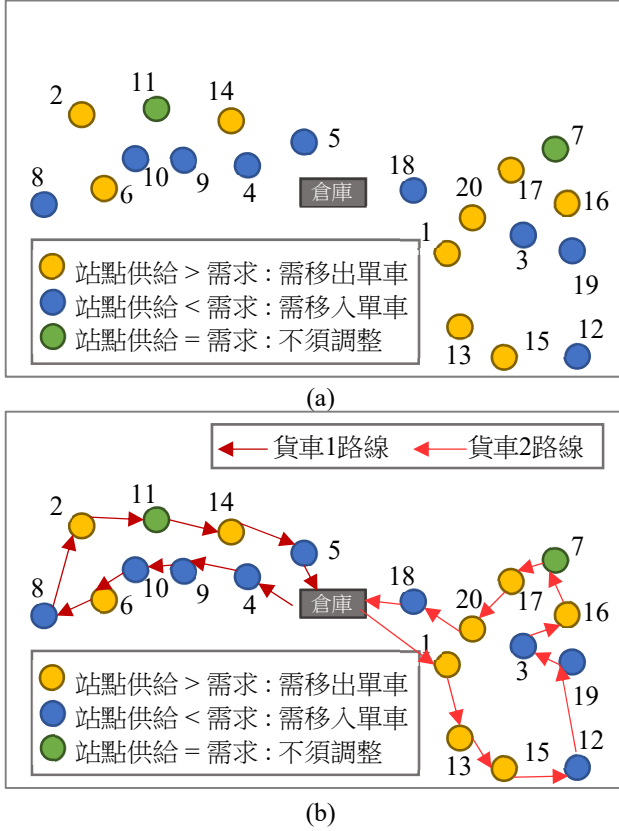


圖 3、第二階段再配送問題示意圖。(a)問題實例。
(b)對應此問題實例的路徑解。

4. 第一階段以深度學習法預測共享單車需求

本研究在第一階段以深度學習的 RNN、LSTM、GRU 三個模型來預測共享單車需求量，此三模型之介紹如下：

- 1) 循環神經網路(RNN)：RNN的目標是希望能透過觀察序列中的先前步驟進而預測該序列下一步的情況，RNN結構圖如圖4所示。在RNN中，隱藏層便是用於儲存有序數據中早期所捕獲到的資訊，計算公式如下：

$$O_t = g(V \cdot S_t)$$

$$S_t = f(U \cdot X_t + W \cdot S_{t-1})$$

當中 X 、 S 、 O 皆為向量，分別代表的是輸入層、隱藏層、輸出層的值，而 U 則代表輸入層到隱藏層的權重矩陣； V 代表隱藏層到輸出層的權重矩陣； W 代表隱藏層上一次值的權重矩陣。由圖可以明顯得知 S_t 的值不僅僅取決於 X_t ，而且還取決於 S_{t-1} ，代表可以紀錄先前所觀察到的資訊並預測下一步的情況，但其缺點也相對明顯(梯度消失)。




圖 4、RNN 結構圖

- 2) 長短期記憶神經網路(LSTM)：典型RNN的主要限制在於該種神經網路只能記住序列中較早的幾個步驟，一旦距離當前的時間步越長，那麼其反饋的梯度訊號則會越不顯著，這就意味著RNN對於長距離資料含意的捕捉能力失效了(梯度消失)，因此為了克服這個缺點，因此開發出LSTM演算法，旨在解決梯度消失的問題。LSTM是一種特殊的RNN架構，該模型可以處理有序數據並長期記憶過去時間步長的數據，因此LSTM並不受梯度消失或梯度爆炸的問題影響，LSTM結構圖如圖5所示，而其使用之公式如下：

$$O_t = \sigma(W_o[h_{t-1}, X_t] + b_o)$$

$$f_t = \sigma(W_f[h_{t-1}, X_t] + b_f)$$

$$i_t = \sigma(W_i[h_{t-1}, X_t] + b_i)$$

$$\tilde{C}_t = \tanh(W_c \times [h_{t-1}, X_t] + b_c)$$

$$C_t = f_t \odot C_{t-1} + i_t \odot \tilde{C}_t$$

$$h_t = O_t \odot \tanh(C_t)$$

當中 t 代表當前步驟， X 代表輸入， b 代表偏差， W 代表權重矩陣。我們可以發現每個 LSTM 單元的狀態可以分為兩個向量，短期狀態 h_t 和長期狀態 C_t ，這兩個狀態由三個門控制：遺忘門(f_t)、輸出門(O_t)、輸入門(i_t)。

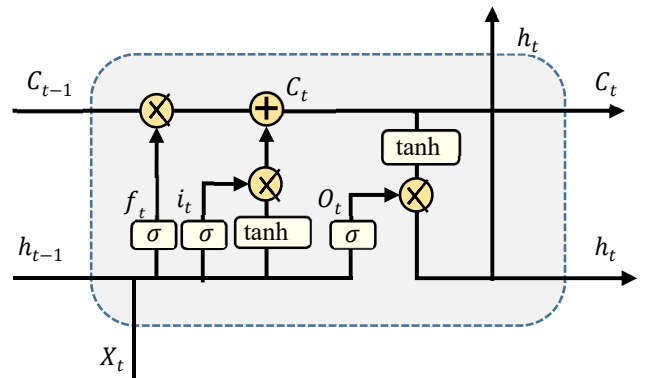


圖 5、LSTM 結構圖

由於Sigmoid函式產生一個介於0到1之間的值，一旦與不同時刻的狀態相乘後，便可當作控制狀態資訊保留多寡的一種手段。輸入門可以決定當前狀態中需要保存甚麼資訊；輸出門則可以決定要從 C_t 中輸出甚麼資

訊；遺忘門可以控制上一個時刻的長期狀態(C_{t-1})捨棄哪一部分的資訊， \tilde{C}_t 則是透過上一狀態輸出和當前狀態輸入結合並透過 \tanh 激活函數生成，而有了遺忘門和輸入門後便可得到下一完整時刻的 C_t ，不論在哪個時間步都會保留一些記憶並添加一些記憶，因此基於這些特性，LSTM 對梯度消失問題有很大幫助，並允許神經網絡學習甚至是長程依賴關係，而該模型則可以自己學習需要丟棄或添加什麼資訊。

- 3) 門控循環單元(GRU)：GRU式循環神經網路(RNN)的一種，和LSTM一樣，該技術也是為了解決反向傳播中的梯度問題而被提出的，事實上GRU和LSTM在很多情況的表現上相差無幾，但相較於LSTM來說，GRU技術大幅加快執行速度以及減少記憶體耗用，其原因來自於參數的減少，GRU參數部分僅使用更新門(z_t)、重置門(r_t)兩種門控和一種狀態 h_t ，GRU結構圖如圖6所示，所使用的公式如下：

$$\begin{aligned} z_t &= \sigma(W_z \cdot [h_{t-1}, X_t]) \\ r_t &= \sigma(W_r \cdot [h_{t-1}, X_t]) \\ \tilde{h}_t &= \tanh(W \cdot [r_t \odot h_{t-1}, X_t]) \\ h_t &= (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t \end{aligned}$$

當中重置門(r_t)控制該有多少比例的上一個 h_{t-1} 和新讀入的 X_t 計算下一個「準」 \tilde{h}_t ；而更新門則是調配「準」 \tilde{h}_t 和上一個 h_{t-1} 的比例，來得到最終的 h_t 。

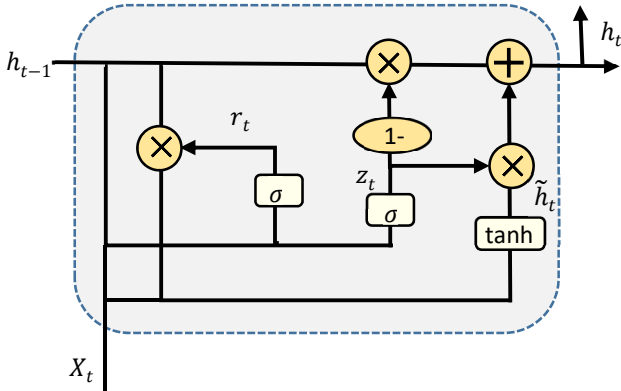


圖 6、GRU 結構圖

為了避免梯度消失或爆炸的問題，因此本研究主要使用 LSTM、GRU 技術為預測的基礎結構。

5. 第二階段以基因演算法找出最佳再配送路徑

本研究第二階段以基因演算法找出最佳再配送路徑，本章首先建立最佳再配送路徑問題之數學模型，接著提出基因演算法求解此問題。

5.1 建立再配送路徑問題之實際數學模型

如問題設定所述，我們會根據預測的結果將共享單車的站點分成預測之每小時進站量大於出站量、預測之每小時進站量小於出站量以及預測之每小時進站量等於出站

量三種，且我們會在最一開始將不需調整的站點剔除。因此，本研究第二階段問題是一種 VRPPD，此問題考慮物流作業由預測結果決定，並訂定目標在找出此再配送過程中運輸距離及碳排放成本最低的最佳路徑。本研究問題與過去研究差異如下：

過去研究如(Hu et al., 2021)中的再配送僅考慮時間成本，然而我們以提前一個小時的預測結果再配送之設計已將時間成本的上下界考量在研究假設中，也就是說，在本研究中若路線距離大於我們保守估計一個小時內貨車等速率繞完的值，程式幾乎不會選擇該路線。雖然該論文沒有考量最重要的碳排放問題，僅以距離和時間窗限制安排再配送路線，但該篇論文的數學基本架構定義的相當完善，所以我們選擇利用該論文數學模型作為我們模型的基礎，並且在此說明以感謝他們的貢獻。

過去研究如(Qin et al., 2021) 對碳排放有非常詳盡的研究，且通過該最小化碳排放模型降低了 57.5%的排放量。此外，該論文說明共享單車系統的再配送通常由化石燃料貨車完成，目前已有不同的燃料消耗和二氧化碳排放模型用於評估車輛路徑問題的環境影響。在大多數模型中，衡量 CO₂ 排放的變量因子主要包括車速、加速度、坡度、負載和車輛燃油類型。我們在最佳化的目標式中套入該研究的假設：忽略道路擁堵情況，將調度貨車的速度視為一個常數。該研究證實 CO₂ 排放量與貨車負載，和該負載下貨車行駛的距離有關。該研究提出的 CO₂ 排放量公式下：

$$f = (F^* - F) / Q$$

其中 F^* 表示貨車滿載時的碳排放因子， F 表示空車時貨車固定的碳排放因子； Q 表示再配送貨車的容量，公式 f 代表再配送貨車負載增加一輛共用單車所引起的碳排放增量。此外，後續我們將參考歐盟於 2020 年規定貨車碳排放限制為原則，即每公里排放 95 公克二氧化碳的限制。雖然該篇論文在共享單車再配送之貨車碳排放的公式定義清楚、符合邏輯且有實驗證實其實用性很高，但該篇研究在數學建模時僅以經濟成本為首要考量，且著重在定價策略分析，故我們只採用該篇論文在碳排放中定義與載重相關之公式作為我們最佳化目標之一。

本研究的再配送模型將參考 (Hu et al., 2021) 的架構為基礎，碳排放成本模型參考(Qin, M et al., 2021) 的模型，以最小化共享單車系統的運輸成本和碳排放成本為雙目標問題。此問題模型所使用之參數及數學符號定義如下：

集合：

- V 代表所有站點的集合，即某次行程中需要重新平衡的站點總數，包含再配送中心 $\{0\}$ 是每次旅行唯一可多次造訪的站點。

參數：

- N 代表系統貨車總數量。
- α 代表運輸成本的權重值。
- β 代表碳排放成本的權重值。
- Q 代表貨車可以承載的最大單車數量。
- M 代表一個接近無窮大的數字。

- y_i 代表貨車在站*i*移入貨移出的共享單車數量；
 $y_i > 0$ 表示貨車將單車移出站點(裝載)；
 $y_i < 0$ 表示貨車將單車移入站點(卸載)。
- F 代表貨車空載時的CO₂排放因子，0.7725kg/km。
- F^* 代表貨車滿載時的CO₂排放因子，1.1017kg/km。
- d_{ij} 代站*i*移動到站*j*的距離，採用二維座標直線距離。

決策變數：

- g_{ij} 代表貨車從站*i*移動到站*j*時載送的單車數量。
- p_i 代表站點*i*平衡前的共享單車數量。
- s_i 代表站點*i*平衡後的共享單車數量。
- q_i 代表站點*i*的目標單車數量，由預測模型決定的值。
- $x_{ij} = \begin{cases} 1, & \text{貨車從站}i\text{移動到站}j\text{時。} \\ 0, & \text{貨車沒從站}i\text{移動到站}j\text{。} \end{cases}, \forall i \neq j$
- $y_{ij} =$ 貨車從站*i*移動到站*j*貨車上的共享單車數量。
 若 $x_{ij} = 0, y_{ij} = 0, \forall i \neq j$ 。

數學規劃模型：

$$\begin{aligned} \text{Min } Z &= \alpha z_1 + \beta z_2 \\ &= \alpha \cdot (\sum_{i=0}^n \sum_{j=0}^n X_{ij} d_{ij}) + \\ &\quad \beta \cdot (\sum_{i=1}^n \sum_{j=1}^n y_{ij} \cdot [(F^* - F)/Q] \cdot d_{ij} \cdot X_{ij}) \end{aligned}$$

s.t.

$$\begin{aligned} s_i &= p_i - y_i \quad \forall i \in V \\ \sum_{i=0, i \neq j}^n x_{ij} &= 1, \forall j \in V \setminus \{0\} \\ \sum_{j=0, i \neq j}^n x_{ij} &= 1, \forall i \in V \setminus \{0\} \\ \sum_{i=0}^n x_{ip} &= \sum_{i=0}^n x_{pj} \quad i \neq p, j \neq p, \forall p \in V \setminus \{0\} \\ g_{ij} &\in \mathbb{Z}^+ \text{ and } g_{ij} \leq Q \times X_{ij} \quad \forall i, j \in V, i \neq j \\ \sum_{j=0}^n g_{ji} + p_i &= \sum_{j=0}^n g_{ij} + q_i, \forall i \in V \setminus \{0\} \\ y_i &= \begin{cases} \min(q_i - p_i, y_{ij}), & \text{if } p_i - q_i < 0 \\ p_i - q_i, & \text{if } p_i - q_i > 0 \end{cases}, \forall i, j \in V \\ X_{ij} &= \{0, 1\} \\ y_i &\geq 0, \forall i \in \mathbb{Z}, \forall i \in V \\ y_{ij} &\geq 0, \forall i \in \mathbb{Z}, \forall i \in V \\ s_i &\geq 0, \forall i \in \mathbb{Z}, \forall i \in V \\ q_i &\geq 0, \forall i \in V \end{aligned}$$

目標式之最小化 $Z = \alpha z_1 + \beta z_2$ 再配送階段的距離及再配送貨車碳排放之兩個目標分別說明如下：

- 1) 運輸成本：貨車的行程必須很短，以盡量減少運輸成本。卡車為一次行程執行再平衡所經過的距離如下公式所示：

$$z_1 = \sum_{i=0}^n \sum_{j=0}^n X_{ij} d_{ij}$$

- 2) 碳排放成本：貨車的碳排放必須很少，以減少運輸成本及對環境的傷害。卡車再配送階段所產生的碳排放總量如以下公式：

$$z_2 = \sum_{i=1}^n \sum_{j=1}^n y_{ij} \cdot [(F^* - F)/Q] \cdot d_{ij} \cdot X_{ij}$$

5.2 以基因演算法找出最佳再配送路徑

為了解決實際規模的問題，我們還需要使用基因演算法來解決本研究問題，此問題是一種 VRPPD，由於 VRPPD 是 NP-hard 問題，且本研究所提出的混合整數線性規劃模型涉及許多變數以及限制式，因此本研究採用了一個基因演算法(Holland, 1975)以解決上述的問題。基因演算法是一種應用自然界中物競天擇、適者生存的演化及淘汰的概念，基因演算法將欲求解的問題參數以一種類似染色體的資料結構編碼，並運用一些遺傳運算子，如交配或突變等，對類似染色體的資料作運算，運算後產生的子代除具有親代的優勢特質外，也有機會因基因的交配或突變而得到比親代更佳子代，比起一般傳統的最佳化方法，基因演算法可以處理多參數的最佳化問題，且是採多點搜尋，可以跳脫局部最佳解，使得我們能夠得到本問題近似全域的最佳解，因此我們將採用基因演算法作為本研究問題的最佳化演算法。

基因演算法的搜尋方式不同於以往的單點搜尋，而是採用多點搜尋，且可以處理多參數的最佳化問題，不易掉入局部解，也因此適用於大規模的最佳化問題。本研究之基因演算法如圖 7 及 Algorithm 1 所示，其解釋如下：考慮一個擁有多個染色體的群體，且每個染色體代表問題的一個解。基因演算法從隨機產生初始化群體開始(第 1 行)，並計算此初始化群體的適應度(第 2 行)。接下來在到達最大迴圈數前，迴圈第 3 行至第 9 行循環的重複從當前群體中挑選親代染色體(第 4 行)，並對此親代染色體執行基因演算法運算子，即交配(第 5 行)和突變(第 6 行)，以繁衍出子代染色體，再計算此子代染色體的適應度(第 7 行)，若子代染色體表現較佳，則取代親代染色體(第 8 行)，重複執行上述動作直到到達最大迴圈數(第 9 行)，最後，輸出群體裡擁有最佳適應度的染色體，以作為此基因演算法的解(第 10 行)。接著，此基因演算法中的詳細操作詳述如下。

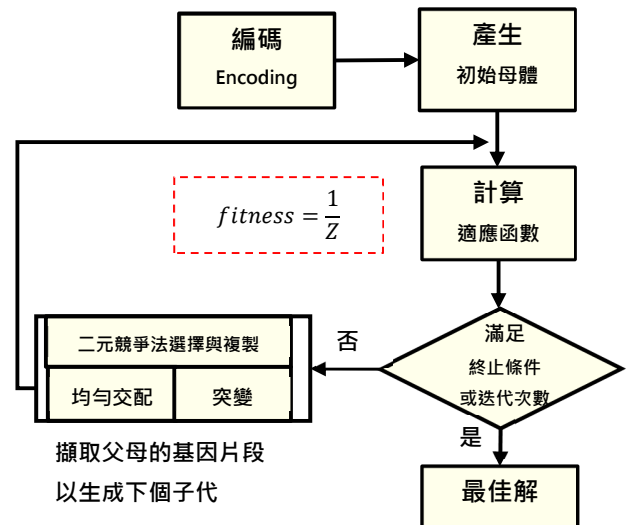


圖 7、基因演算法流程圖

Algorithm 1 基因演算法

- 1: 隨機產生初始化群體 P
- 2: 計算初始化群體 P 所有染色體的適應度
- 3: **while** 到達最大迴圈數 **do**
- 4: 利用二元競爭式選擇法從 P 中挑選親代 P_{parent}
- 5: 在交配率為 P_c 的情況下，對親代 P_{parent} 進行單點交配，繁衍子代 $P_{\text{offspring}}$
- 6: 在突變率為 P_m 的情況下，隨機選擇子代 $P_{\text{offspring}}$ 的一些染色體進行突變
- 7: 計算子代 $P_{\text{offspring}}$ 所有染色體的適應度
- 8: 以子代 $P_{\text{offspring}}$ 表現較佳的染色體取代群體 P 表現較不佳的染色體
- 9: **end while**
- 10: 輸出群體 P 表現最佳的染色體

5.2.1 貨車虛擬座標

由於貨車的路徑要運送單車至多個站點，因此我們使用一個貨車的虛擬座標來象徵它可對應到多個站點的意義，這個概念類似分群的虛擬重心。如圖 8 所示，紅色三角形為貨車虛擬座標，以 5 號站點為例，演算法一開始會先計算 5 號站點到貨車 1、貨車 2 及貨車 3 的距離，在此例中顯然與站點 5 距離最近的貨車是 1 號貨車，所以我們就會把站點 5 分到由貨車 1 配送的群中。圖 9 為將圖 8 依照上述流程將每個站點分到最近的站點之後的分群結果。

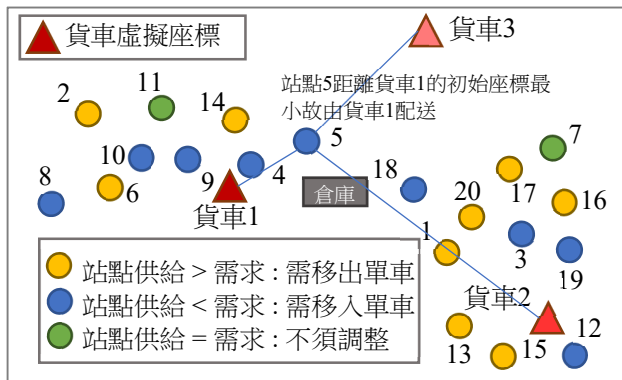


圖 8、第二階段再配送問題實例之示意圖




圖 9、以圖 3(a)各站點與貨車之距分群結果示意圖

5.2.2 解的編碼

本研究之基因演算法的染色體(即問題的一個解)以 (k_1, k_2, \dots, k_n) 、 $(b_1, b_2, \dots, b_{2V})$ 表示，由以下兩個決策變數所組成：

- (k_1, k_2, \dots, k_n) 為一個 $\{1, 2, \dots, n\}$ 的亂數排列，數字表示站點編號，用以決定卡車的路徑，其中 n 為站點之數量。
- $(b_1, b_2, \dots, b_{2V})$ 為貨車初始虛擬經緯度排列，用以將站點依照遠近分配給貨車，其中 V 為貨車之數量。

例如，當 $n = 20$ 、 $C = 3$ 時，其編碼如圖 14 所示，第一部分表示分配給貨車的站點順序，意即從 5 號站點開始將其分配給距離虛擬經緯度最近的貨車，第二部分則兩個數字一組，表示貨車的虛擬經緯度，用以上述分配站點使用。

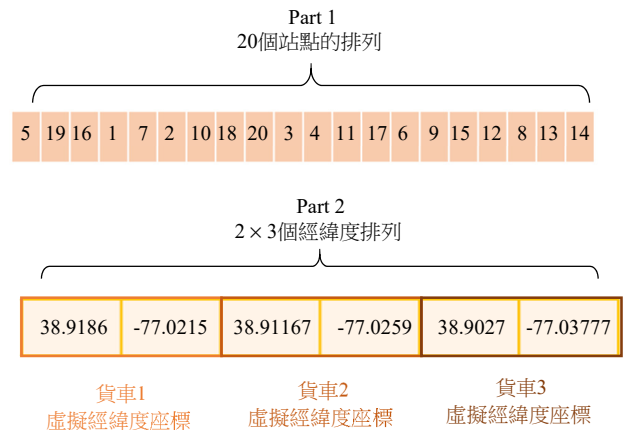


圖 10、以圖 8 為例所產生的一個解之編碼

5.2.3 適應度值的計算

本研究將成本函數設定為目標式(1)，以最小化貨車總距離及最小化碳排放量之雙目標求解，本研究之基因演算法所得之最佳解為行駛總距離最少時排放最少碳的解。

給定一組染色體 (k_1, k_2, \dots, k_n) 、 $(b_1, b_2, \dots, b_{2C})$ ，適應度值根據前述混合整數線性規劃模型之限制式(2)至限制式(13)計算，以取得最小之適應度值，且當違背限制式，如貨車即時載重超過最大載重，或是小於 0 時，將適應度值，也就是行使距離設為 100000。

5.2.4 基因演算法中操作的詳細說明

本節將介紹基因演算法中演化的過程，包含初始化、複製、交配及突變。首先介紹如何初始化群體，群體裡每組染色體 (k_1, k_2, \dots, k_n) 、 $(b_1, b_2, \dots, b_{2C})$ 表示，染色體裡的每個數字為一基因，第一部分由 $\{1, 2, \dots, n\}$ 隨機排列，第二部分 b_{2t-1} 為隨機貨車虛擬緯度，均勻隨機範圍設定為(38.88, 38.92)， b_{2t} 為貨車虛擬經度，均勻隨機範圍設定為(-77.01, -77.04)，其中 $t = 1, 2, 3, \dots, C$ 。

接著將進行演化的過程，首先利用二元競爭式選擇法從初始化群體中選擇染色體以做為親代，且是選擇具有較低成本的染色體，二元競爭式選擇法的概念如下：模仿自然界中生物彼此競爭的概念，當某一個體的適應度越高，其經由競爭後存活下來而被複製的機會越高，此選擇法的

好處為染色體被複製的機率與染色體間適應度相對值大小無關，而是取決於染色體間適應度的相對大小，因此適合處理個體間適應度值相對變化很大的問題，其運作方法為：從群體中隨機選取 2 個染色體，並比較其適應度，適應度較優者做為親代複製保存至子代，重複此動作直到子代總數等於群體大小。

複製完成後，本研究使用均勻交配以進行交配的程序，交配的概念如下：從先前複製過程後所產生的子代中，隨機選取兩個染色體，並將這兩個染色體的基因重新排列組合，以產生兩個新的染色體。均勻交配的程序如下：首先設定交配率，接著隨機產生一個機率值，若是此隨機值小於先前所定義的交配率，便進行交配，反之則不需進行交配的程序。若需進行交配，首先隨機兩組長度為 n 以及 $2C$ 的遮罩，遮罩由 0 和 1 組成，根據染色體對應遮罩位置數字，若數字為 1 的位置則將需進行交配的兩個染色體基因對調，重新組合成兩個新的子代染色體。

交配完成後演化過程還需進行突變，突變的概念及程序如下：首先從先前交配過程後所產生的子代染色體中，隨機選取一個染色體，再隨機選取兩個突變點，並定義突變率，接著隨機產生一個機率值，若是此值小於先前所定義的突變率，便進行突變，反之則不需進行突變的程序。若需進行突變，第一部分的染色體對指定之突變點的基因數值對換，從而產生新的染色體，第二部分的染色體對指定之突變點的基因數值，依照初始化設定的範圍重新隨機產生數值，從而產生新的染色體。突變的好處為可將染色體的特性做一立即的改變，使搜尋的點更加分散，以防止過早收斂於局部最佳解，而無法獲得全域最佳解。

突變完成後，基因演算法還需進行最後一個步驟，及計算子代的適應度並執行取代，首先計算子代所有的染色體之適應度，若是此染色體的適應度優於原先群體裡的染色體適應度，則以子代之染色體取代之。

重複上述動作達到最大迴圈數，最後輸出群體裡適應度最優的染色體，即完成基因演算法。

6. 實驗結果與分析

本章首先描述實驗資料和資料前處理，接著評估深度學習預測模型的表現，接著說明基因演算法在實驗環境中的效能，透過不同問題及演算法之參數設定，執行收斂速度分析及穩定性分析。

6.1 資料描述及資料前處理

本研究使用 2018 至 2021 年 Capital Bikeshare 平台中華盛頓特區的共享單車數據來作為此次實驗研究的資料集。在數據集中總共包含 800 多個共享單車站點，然而經過分析後發現有部分站點的共享單車租賃量十分稀缺，基本上不會發生共享單車不足或無樁可停的情況，此外，由於 LSTM、GRU 等模型對數據的質量有嚴格的限制，當站點的單車進站、出站數量基本為 0 時，其預測效果會不盡理想，因此，最終採取共享單車租賃筆數前 20 大的站點進行模型建立及預測來保持預測的準確度及實用性。

原始數據包含多維度的資訊，其中包括空間、時間和

客戶資訊。在此模型中，我們將每台共享單車行程的開始時間、結束時間、起點站和終點站等資訊統整成車站數據（每小時站點的單車進站、出站數量）。此外，我們有根據所有站點的單車租借數據集進行分析，可以發現時間因素對於模型預測相當重要，下午及早晨的單車租借量和凌晨有蠻大的差異（圖 11），不同月份下的單車租賃狀況也有一定的差距（圖 12），在年份的維度下，分析發現在 2020 年的單車租借量和以往有顯著差異，推測可能是因為疫情出現並爆發的階段（圖 13），導致共享單車的租借量大幅下降。根據上述分析後，我們決定把時間和月份作為特徵輸入，除了時間和月份外，我們亦有額外加入星期來作為特徵之一，嘗試是否能提高預測準確性。




圖 11、時間區段和共享單車租借筆數




圖 12、月份和共享單車租借筆數




圖 13、年份和共享單車租借筆數

本研究使用 GRU、LSTM 作為預測基礎。為了避免不同星期對模型造成潛在影響，因此本研究決定以 7 天的資料為一個循環來進行下個時間點的預測。此外，該研究所使用的是標準多層的 LSTM 模型，如圖 14 所示，LSTM 模型主要分成 2 層、4 層 LSTM 做效能比較，而為了讓 GRU 參數少、計算快的優點突出，GRU 則採用 2 層架構作為對照。編譯時的 optimizer 的選擇則是使用 Adam，而 loss 的選擇則是 mse。




圖 14、LSTM 架構

本研究評估方式是選擇均方誤差 (MSE)、平均絕對誤差 (MAE) 來衡量不同模型的效能，公式如下：

$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|$$

其中 N 是測試樣本的數量， y_i 是真實數據， \hat{y}_i 是對應的預測。

6.2 預測效果評估

本研究利用 Keras 中的 LSTM、GRU 來建立預測模型。此外，本研究利用下列三種不同的模型架構來進行預測，並針對這三種的預測結果進行誤差評估、比較：

- 1) 架構1：我們將LSTM堆疊二層後加上一層Dropout層來防止過擬和，最後再堆疊兩層的全連接層來輸出。
- 2) 架構2：我們將LSTM堆疊四層後加上一層Dropout層來防止過擬和，最後再堆疊兩層的全連接層來輸出。
- 3) 架構3：我們將GRU堆疊二層後加上一層Dropout層來防止過擬和，最後再堆疊兩層的全連接層來輸出。

圖 15-20 便是架構 1、2、3 進出站模型的 MSE 值。不論任何架構下的 MSE 皆會遵循一定的規律產生，例如，不論哪個架構下的 MSE 均為 Station 2 最為嚴重，除此之外，我們可以發現出站模型的 MSE 通常會比進站模型的 MSE 來的更小。

圖 21-26 便是架構 1、2、3 進出站模型的 MAE 值。相較於 MSE 來說，各站點 MAE 值的分布狀況更為平均，不論是哪個架構下的進出站，不會出現極大或極小的離群值產生。

除此之外，不論在何種架構下的進出站模型皆有一現象發生，由於站點編號越大代表是過去單車租賃量越小，而隨著單車租賃量減少其預測模型的誤差 MSE、MAE 則也趨近越小，此處推論是因為單車進站數量的縮減導致模型訓練時的不會有過多的離群值影響模型，而讓其預測效

果趨於穩定。

以預測能力來說的話，LSTM 的預測能力的確是和 GRU 相差不少，而當我們針對建構 20 個站點模型的速度進行比較時，GRU 也的確相較於快上許多，但由於是利用 Colab 的 GPU 資源去訓練，可能每個時段所分配到的運算量也會有所不同，在這裡無法給出實際時間數據比較。

6.3 實驗環境與設定

本研究提出之基因演算法是以 Python 程式語言所實現的，並在配備本論文使用 Google Colab 進行模型訓練的環境建置，不論何種作業系統與硬體設備，即可使用免費且高效能的 GPU，內建多項函式庫讓使用者不用事先安裝即可使用，對於新手或老手而言都是方便且好用的環境。此外 Colab 結合雲端硬碟的共用設計也可以方便我們團隊合作，能讓預測模型輸出的值到自動匯出輸入下一步的載配送規劃，除了深度學習模型會需要稍微久的運作時間外，基本上是本研究相當理想的建置環境。實驗中站點座標使用 Capital bikeshare 公司的站點經緯度實際資料，在二維區域內真實呈現成，倉庫位置則設在各站點座標平均，所有站點及倉庫之間的距離的計算都是指二維座標直線距離，其他參數設定如表 1 所示。

表 1、參數設定

參數	符號	值	單位
站點數量	n	20	個
消耗的燃油	f_c	10	L/100km
貨車空載時的CO ₂ 排放因子	F	0.7725	kg/km
總功率轉換效率	η_p	0.9	效率無單位
車輛生產及處置階段對利用階段的碳排放量比率	α	0.5	常數無單位
重力加速度	g	9.8	m/s ²
貨車可承載最大單車數量	Q	30	台
貨車初始承載單車數量	Q_0	15	台
貨車數量	C	3	台
貨車滿載時的CO ₂ 排放因子	F^*	1.1017	kg/km

5.1 收斂分析

對四組不同的 P_c 和 P_m 組合的參數設定進行收斂速度分析，如圖 27 所示，所有組合皆傾向收斂，其中當 $P_c = 0.8$ 和 $P_m = 0.1$ 時，可得最佳解，且有最佳的收斂效率，因此本研究接下來將使用此參數設定。

圖28為當 $P_c=0.8$ 和 $P_m=0.1$ 時，最佳適應度值和平均適應度值的走向，由此可知基因演算法應用於解決本研究問題時，可確實收斂，且收斂速度非常快。

5.2 穩定性分析

對四組不同的 P_c 和 P_m 組合的參數設定進行穩定性分析，如圖29所示，由圖可知當 $P_c = 0.8$ 和 $P_m = 0.2$ 時，可得到最小的平均適應度及最小的四分位距，具有最佳的穩定性。

圖30為根據上述所得之擁有最佳穩定性之參數設定，當 $P_c = 0.8$ $P_m = 0.2$ ，程式分別重複跑100次的所得之適應度值的折線圖，由圖三十可知，基因演算法應用於解決本研究問題時，所得之結果是相當穩定的。




圖 15、二層 LSTM 進站模型之 MSE




圖 17、四層 LSTM 進站模型之 MSE




圖 19、二層 GRU 進站模型之 MSE




圖 21、二層 LSTM 進站模型之 MAE




圖 23、四層 LSTM 進站模型之 MAE




圖 25、二層 GRU 進站模型之 MAE




圖 16、二層 LSTM 出站模型之 MSE




圖 18、四層 LSTM 出站模型之 MSE




圖 20、二層 GRU 出站模型之 MSE




圖 22、二層 LSTM 出站模型之 MAE




圖 24、四層 LSTM 出站模型之 MAE




圖 26、二層 GRU 出站模型之 MAE




圖 27、收斂分析




圖 28、最佳適應度值和平均適應度值的走向之分析




圖 29、四組 P_c 和 P_m 參數組合的 100 次實驗結果之盒鬚圖




圖 30、程式重複跑 100 次所得之適應度值

6.4 實驗分析與討論

不同問題參數設定之實驗結果比較如表2所示。從表2可知以下資訊，首先我們以直線分隔的三個區域做討論：

- 1) 當共享單車再配送貨車最大載重量固定為10，且初始載重量固定為最大載重量的50%為5時，貨車數量越多，其適應度值越低，代表總距離越長，且碳排放越多。故在貨車最大載重量較少時，約7個站點分配一台貨車是我們推薦總距離最低之下碳排放最少的較理想共享單車系統規劃。

- 2) 當共享單車再配送貨車最大載重固定為20時，我們實驗了三個初始載重佔最大載重量比例，分別是初始載重為最大載重的25%、50%和75%。由我們的實驗結果顯示，50~75%會是比較理想的比例。雖然這個實驗的最佳適應度發生在比例設置為75%且平均一台貨車運送4個站點時。不過，整體而言，當貨車最大載重固定為20時，實驗結果之適應度在約5~7個站點分配一台貨車且初始載重量為最大載重量的50%時，會是總距離及碳排放最低且穩定的系統規劃。
- 3) 當共享單車再配送貨車最大載重固定為30時，我們也實驗了三個初始載重佔最大載重量比例，分別是初始載重為最大載重的25%、50%和75%。與前面實驗結果不同的是，初始載重佔最大載重量的比例幾乎並不影響適應度的值。也就是說，當最大載重量夠大時，初始載重與最大載重量的比例將對總距離及碳排放總量失去影響能力。前面相同的是，最佳適應度都在約5~7個站點分配一台貨車時發生。

表 2、比較不同問題參數設定及實驗結果

Q	Q_0	C	P_c	P_m	Best distance
10	5	3	0.8	0.1	20.173188
10	5	4	0.8	0.1	20.792860
10	5	5	0.8	0.1	23.210680
20	5	3	0.8	0.1	21.254345
20	5	4	0.8	0.1	20.270460
20	5	5	0.8	0.1	21.232755
20	10	3	0.8	0.1	17.383286
20	10	4	0.8	0.1	17.294051
20	10	5	0.8	0.1	18.457814
20	15	3	0.8	0.1	17.699186
20	15	4	0.8	0.1	19.660896
20	15	5	0.8	0.1	17.167029
30	10	3	0.8	0.1	17.777345
30	10	4	0.8	0.1	18.580679
30	10	5	0.8	0.1	18.874622
30	15	3	0.8	0.1	17.189376
30	15	4	0.8	0.1	18.255538
30	15	5	0.8	0.1	18.255538
30	20	3	0.8	0.1	17.777345
30	20	4	0.8	0.1	17.189376
30	20	5	0.8	0.1	18.457814

其次，我們從上述實驗結果分析可得知，如果共享單車系統想要最小化再配送階段的總距離與碳排放，對於共享單車系統之再配送貨車的添購，我們會建議：

- 1) 若預算充足，儘量買最大容量夠多的，在此實驗中約為平均裝載、卸載數量的六倍。
- 2) 若預算不足，最大容量不高時，初始載重量，也就是出倉庫時貨車上的共享單車數量應該要約為最大載重量的50~75%為佳。
- 3) 無論最大載重或初始載重的設計，建議約5~7個站點分配一台貨車。例如在本研究實驗中，我們20個站點的最佳貨車數量就大多落在3或4台。

最後，這三個建議都能夠大幅度的減少總距離及碳排放，達到共享單車系統節能減碳、永續經營的目標。

7. 結論與未來展望

本研究探討了一個深度學習共享單車站點供需預測之下的基因演算法貨車最佳化再配送路徑問題，不同於過去研究多半僅考慮預測或單純再配送，本研究考慮站點供需精準預測及根據預測結果之精實再配送。首先建立了兩個深度學習模型，分別預測站點進站量及出站量，再相減作為後續再配送階段的輸入值，最後建立以最小化總距離及碳排放為再配送階段的雙目標數學模型，以基因演算法來求解此問題，並使用華盛頓特區的 Capital bikeshare 共享單車系統四年來的資料找出影響最大的前二十大站點進行預測及再配送實驗分析與比較。由於 Capital bikeshare 共享單車系統的資料有些缺失值，而且以站點角度的共享單車進出量在前二十大站點也通常只有-5~+5 台。因此目前在本研究的實驗並沒有涵蓋 Capital bikeshare 共享單車系統所有站點。

然而上述問題也並非沒有解決方法，若是未來以我們模型基礎去做拓展也能讓預測與再配送的串接更為流暢。最後，在單車再配送模型中也可以再加入更多目標，例如油資、電價或是碳排放所產生的經濟成本，更符合共享單車系統經營的商業目標。在基因演算法的程式中，我們也缺少能視覺化出地圖及配送路線的功能，未來若結合 UI/UX 前端網頁設計技術，應該能更增加本研究的實用性。

參考文獻

1. Ashqar, H. I., Elhenawy, M., Almannaa, M. H., Ghanem, A., Rakha, H. A., and House, L. (2017) Modeling bike availability in a bike-sharing system using machine learning. In Proc. 5th IEEE International Conference on Models and Technologies for Intelligent Transportation Systems (MT-ITS), pp. 374-378.
2. Bachand-Marleau, J., Lee, B. H. Y., and El-Geneidy, A. M. (2012) Better understanding of factors influencing likelihood of using shared bicycle systems and frequency of use. Transportation Research Record: Journal of the Transportation Research Board, 2314(1), 66-71.
3. Benchimol, M., Benchimol, P., Chappert, B., De La Taille, A., Laroche, F., Meunier, F., and Robinet, L. (2011) Balancing the stations of a self service bike hire system. RAIRO-Operations Research, 45, 37-61.
4. Chen, L., and Jakubowicz, J. (2015) Inferring bike trip patterns from bike sharing system open data. In Proc. of 2015 IEEE International Conference on Big Data, pp. 2898-2900.
5. Chen, Y., Shu, L., and Wang, L. (2017) Poster abstract: Traffic flow prediction with big data: A deep learning based time series model. In Proc. of 2017 IEEE Conference on Computer Communications Workshops (INFORM WKSHPS), pp. 1010-1011.
6. Chen, C. L. P., and Zhang, C.-Y. (2014) Data-intensive applications challenges techniques and technologies: A survey on big data. Information Sciences, 275, 314-347.
7. Choi, S. H., & Han, M. K. (2020) The empirical evaluation of models predicting bike sharing demand. In Proc. of 2020 International Conference on Information and Communication Technology Convergence (ICTC), pp. 1560-1562.
8. Dantzig, G. and Ramser, J. (1959) The Truck Dispatching Problem. Management Science, 6, 80-91.
9. Gast, N., Massonnet, G., Reijnders, D., and Tribastone, M. (2015) Probabilistic forecasts of bike-sharing systems for journey planning. In Proceedings of the 24th ACM international conference on information and knowledge management, pp. 703-712.
10. Gebhart, K., and Noland, R. B. (2014) The impact of weather conditions on bikeshare trips in Washington DC. Transportation, 41(6), 1205-1225.
11. Hou, Y., and Edara, P. (2018) Network scale travel time prediction using deep learning. Transportation Research Record: Journal of the Transportation Research Board, 2672, 115-123.
12. Hu, Z., Huang, K., Zhang, E., Ge, Q., and Yang, X. (2021) Rebalancing strategy for bike-sharing systems based on the model of level of detail. Journal of Advanced Transportation, 2021, 3790888.
13. Kang, Z., Zuo, Y., Huang, Z., Zhou, F., & Chen, P. (2017, October). Research on the forecast of shared bicycle rental demand based on spark machine learning framework. In 2017 16th International Symposium on Distributed Computing and Applications to Business, Engineering and Science (DCABES), pp. 219-222.
14. LeCun, Y., Bengio, Y., and Hinton, G. (2015) Deep learning. Nature, 521(7553), 436-444.
15. Ma, Z., Yu, H., Chen, W., and Guo, J. (2019) Short utterance based speech language identification in intelligent vehicles with time-scale modifications and deep bottleneck features. IEEE Transactions on Vehicular Technology, 68(1), 121-128.
16. Pan, Y., Zheng, R. C., Zhang, J., and Yao, X. (2019) Predicting bike sharing demand using recurrent neural networks. In Procedia Computer Science, 147, 562-566.
17. Qin, M., Wang, J., Chen, W. M., and Wang, K. (2021) Reducing CO₂ emissions from the rebalancing operation of the bike-sharing system in Beijing. Frontiers of Engineering Management, 1-23.
18. Siarni-Namini, S., Tavakoli, N., & Namin, A. S. (2018) A comparison of ARIMA and LSTM in forecasting time series. In 2018 17th IEEE international conference on machine learning and applications (ICMLA), pp. 1394-1401.
19. Xu, M., Liu, H., and Yang, H. (2020) A deep learning based multi-block hybrid model for bike-sharing supply-demand prediction. IEEE Access, 8, 85826-85838.
20. VE, S., & Cho, Y. (2020) Season wise bike sharing demand analysis using random forest algorithm. Computational Intelligence, in press.
21. Wang, B., and Kim, I. (2018). Short-term prediction for bike-sharing service using machine learning. In Transportation Research Procedia, 34, 171-178.